442

pazienti

10 variabili misurate oggi
progressione dopo un anno

QUANTO PEGGIORA IL DIABETE?

Una Ridge Regression sul dataset Diabetes di scikit-learn per prevedere la progressione della malattia a un anno

Progetto Machine Learning di Daniele Acunzo

Il dataset

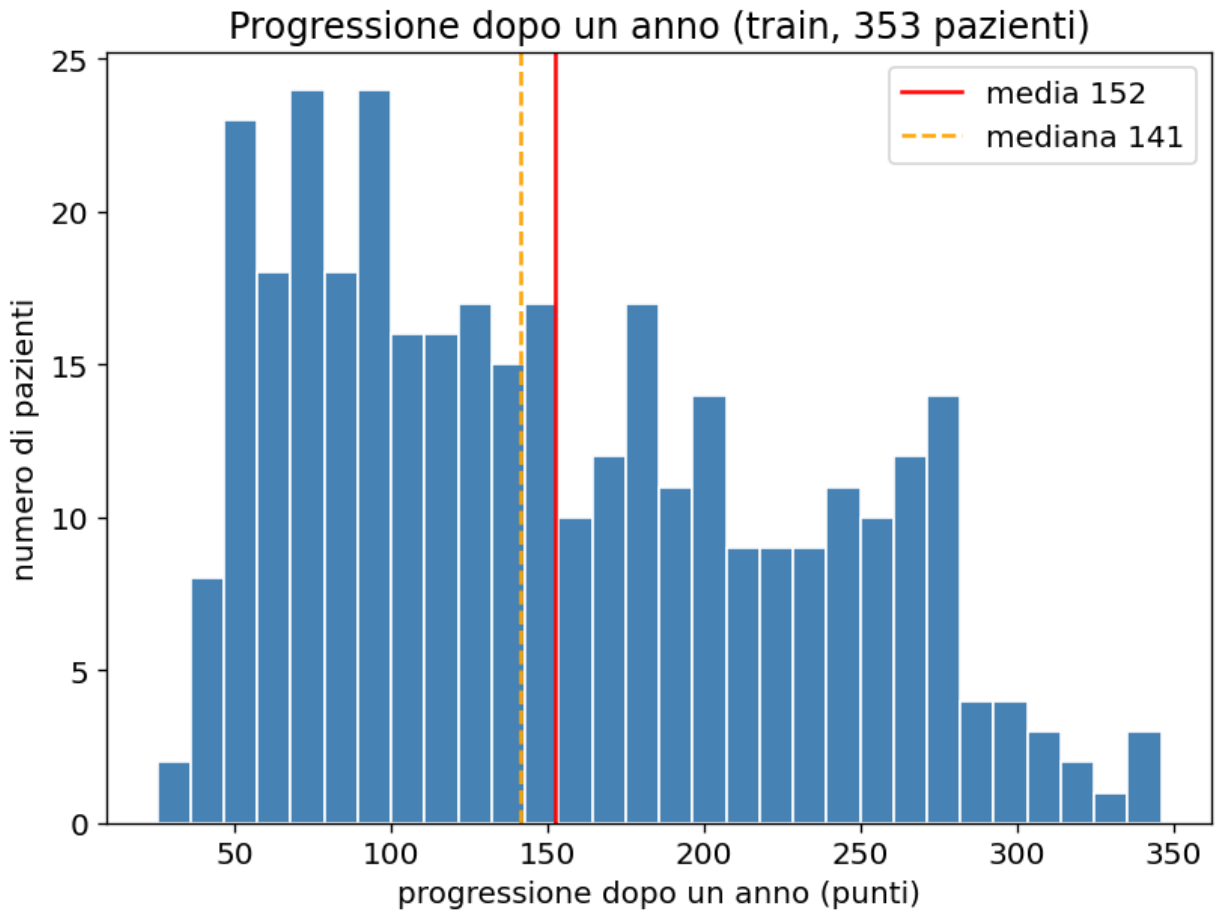
Dataset Diabetes di scikit-learn: cosa c'è dentro e come l'ho caricato

442
pazienti (righe)

10 variabili
età, sesso, BMI, pressione e 6 esami del sangue

Target
progressione della malattia dopo un anno
da 25 a 346, media 152

Dati grezzi
valori originali (scaled=False) · nessun dato mancante



Fonte: dataset Diabetes di scikit-learn

Come ho diviso i dati

80/20 con seed 0 e stratify, lo split lo faccio prima dell'analisi esplorativa

442

pazienti

seed 0 + stratify

Train

353

80% · alleno e scelgo alpha

Cross-validation

5 fold

4 parti allenano, 1 valida, a turno

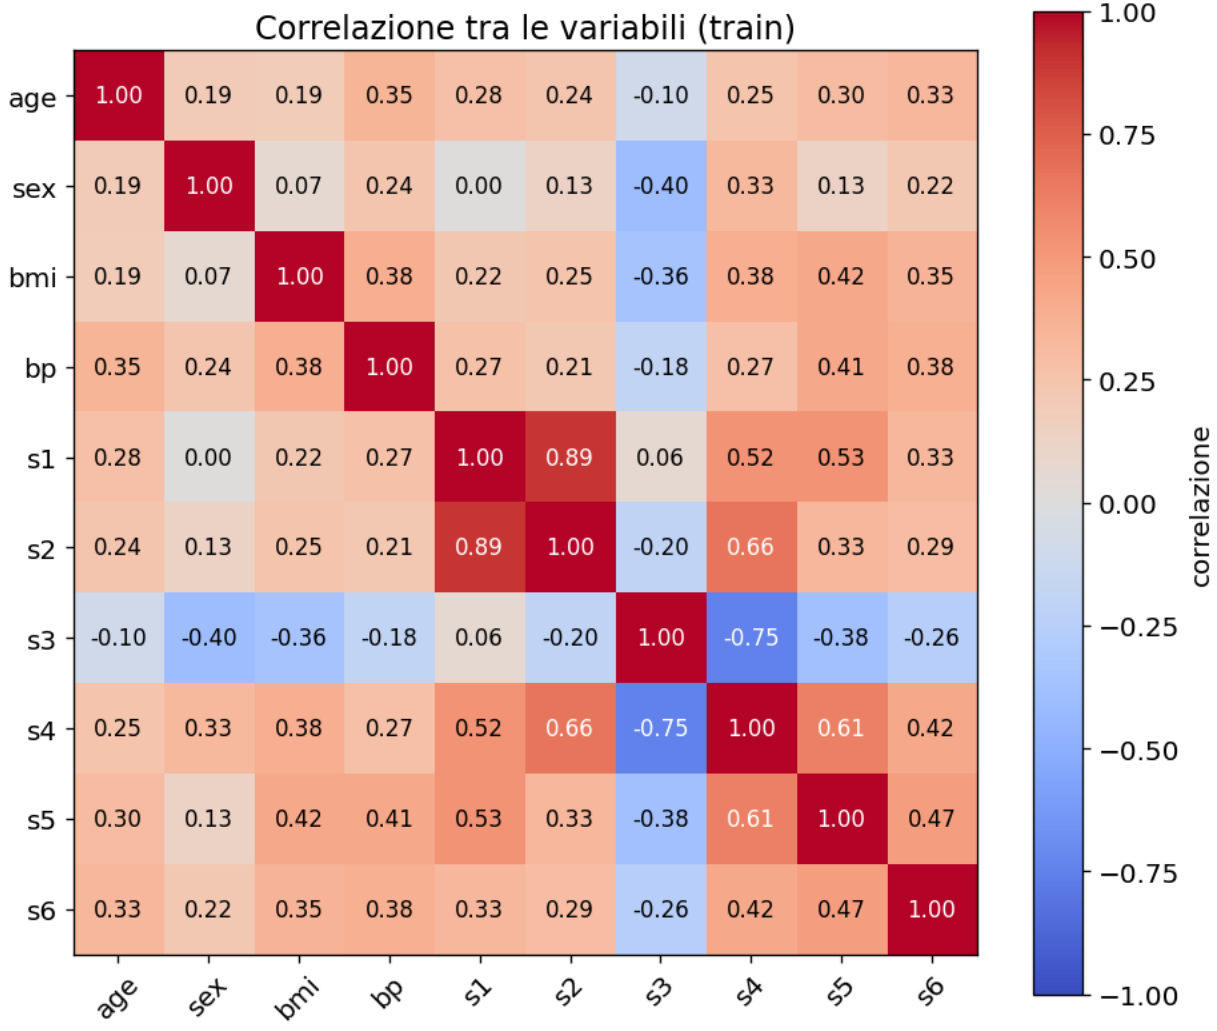
A turno, ogni paziente fa da validation

Test 89 · 20%

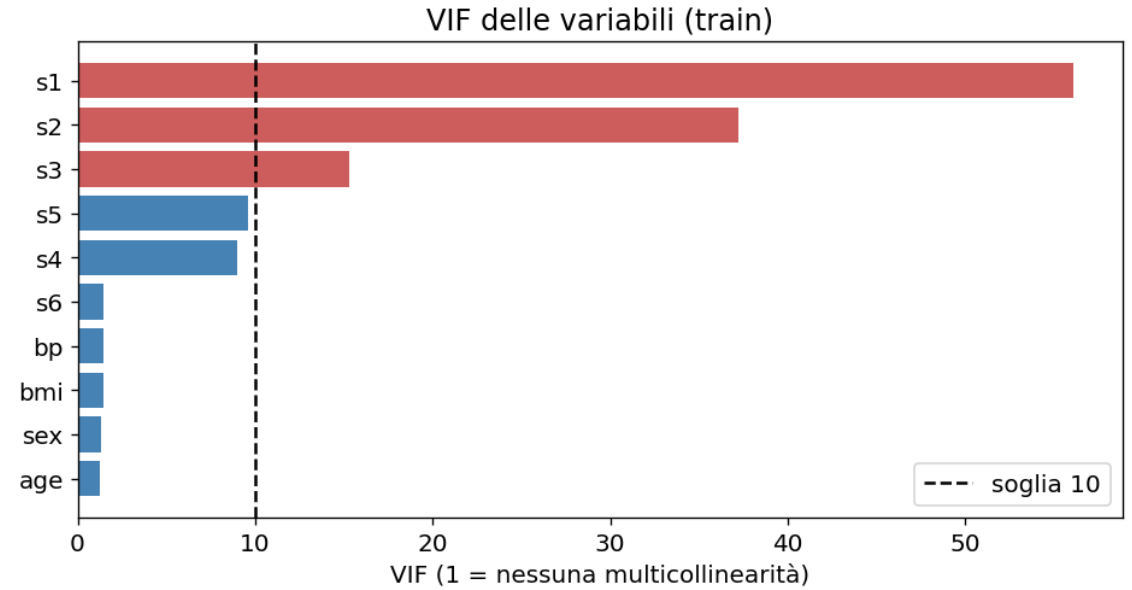
Io uso solo alla fine, una volta sola

Cosa dicono i dati

Analisi esplorativa solo sui 353 pazienti del train, prima di scegliere il modello



Fonte: dataset Diabetes di scikit-learn



Fonte: dataset Diabetes di scikit-learn

Relazioni abbastanza lineari: modello lineare, variabili molto correlate (VIF di s1 56, s2 37): Ridge, scale diverse: StandardScaler

Apri il notebook

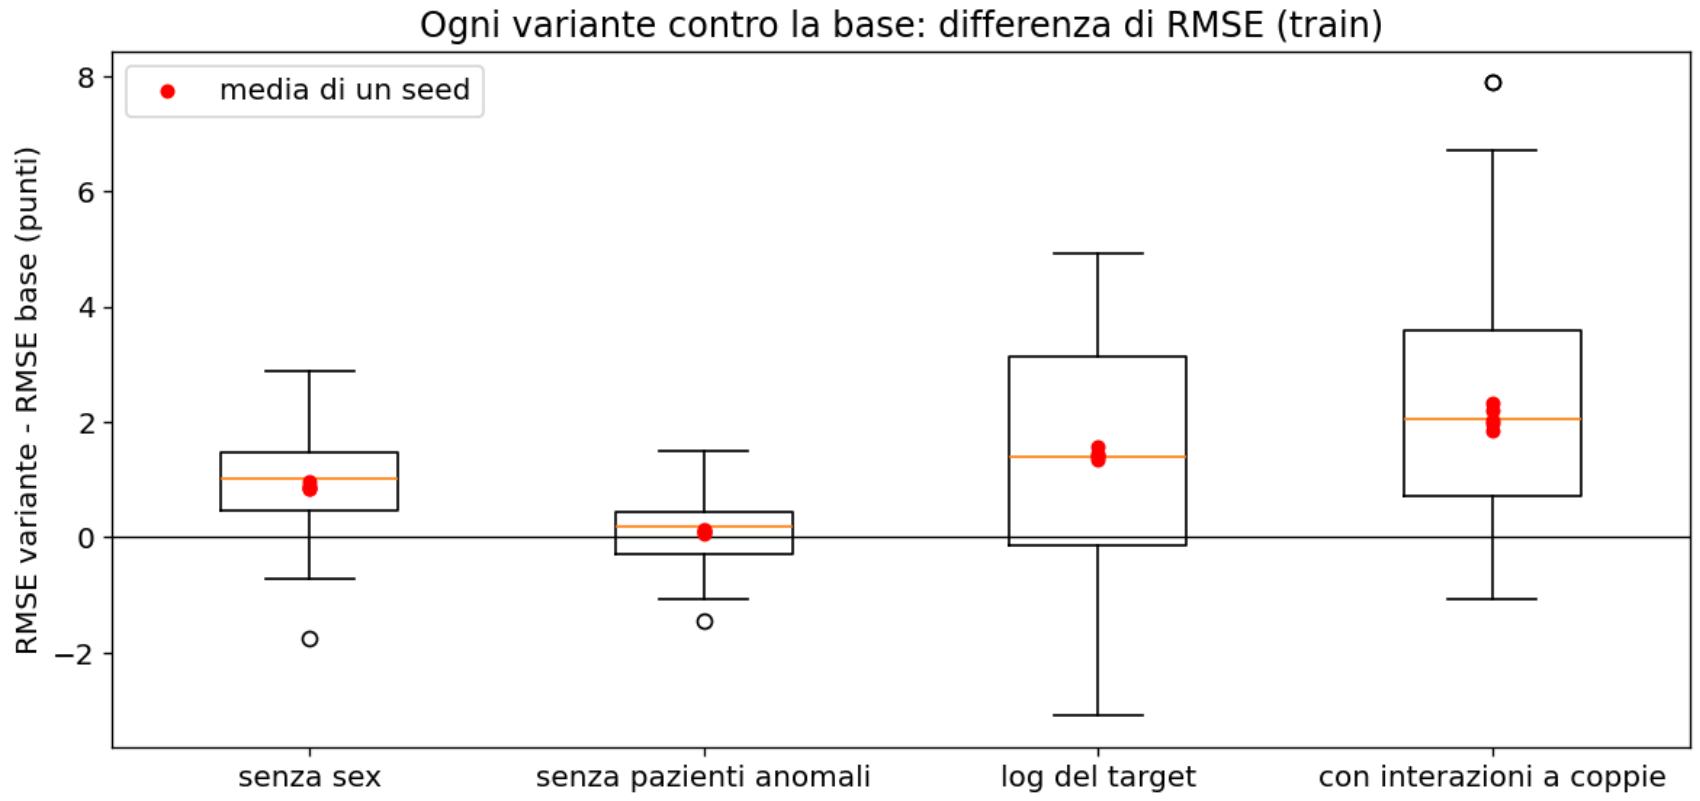
Come ho preparato i dati

Tutto dentro una Pipeline di sklearn, fittata solo sul train

Caricamento	scaled=False: i dati di default sono già scalati su tutti i 442 pazienti, test compreso
Target	ho separato la progressione (y) dalle 10 variabili (X)
Numeriche	StandardScaler: media e deviazione standard le impara solo dal train
sex	OneHotEncoder: una colonna 0/1, non la tratto come un numero
Valori mancanti	nessuno: non mi serve un SimpleImputer
Pipeline	crea_preprocessing(): ogni modello ha il suo preprocessing nuovo

Feature engineering: le decisioni sui dati

Varianti di Ridge contro la base, 50 fold ripetuti con 5 seed diversi, alpha scelto dentro ogni fold



Fonte: dataset Diabetes di scikit-learn

Tengo sex (senza peggiora di circa 0,9 con tutti i seed, ma p da 0,04 a 0,24) e i pazienti anomali (nessun effetto), niente log del target né interazioni (non migliorano)

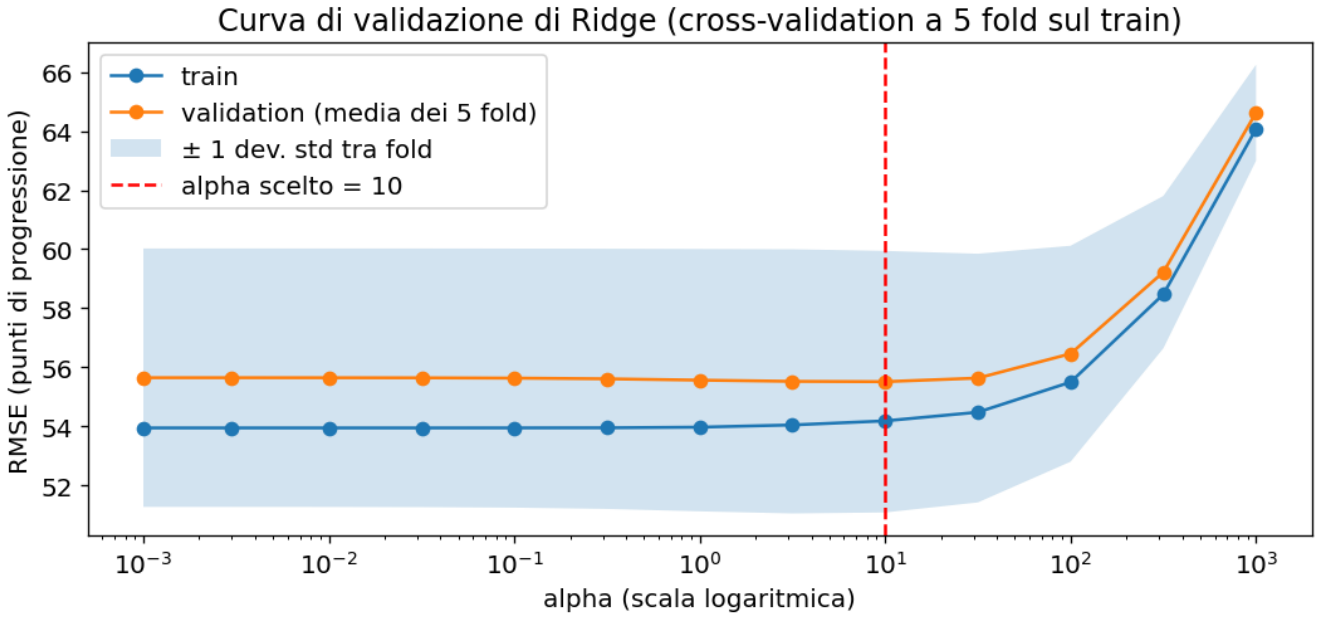
Che cos'è Ridge

Una regressione lineare con un tetto sui pesi, alpha (λ nella teoria) decide quanto è stretto

Regressione	**cerca i pesi che sbagliano meno sul train, senza nessun limite**
Il problema	**s1 e s2 sono gemelle: i pesi diventano esagerati e opposti (-43 e +25)**
Ridge	**aggiunge un tetto alla somma dei pesi al quadrato: niente pesi esagerati**
alpha (λ)	**quanto è stretto il tetto: è l'iperparametro che valido**
alpha piccolo	**tetto altissimo: è come la regressione lineare**
alpha grande	**pesi schiacciati verso zero: il modello non impara (underfitting)**

Quale alpha scegliere?

13 valori da 0,001 a 1000 con GridSearchCV e cross-validation a 5 fold sul train



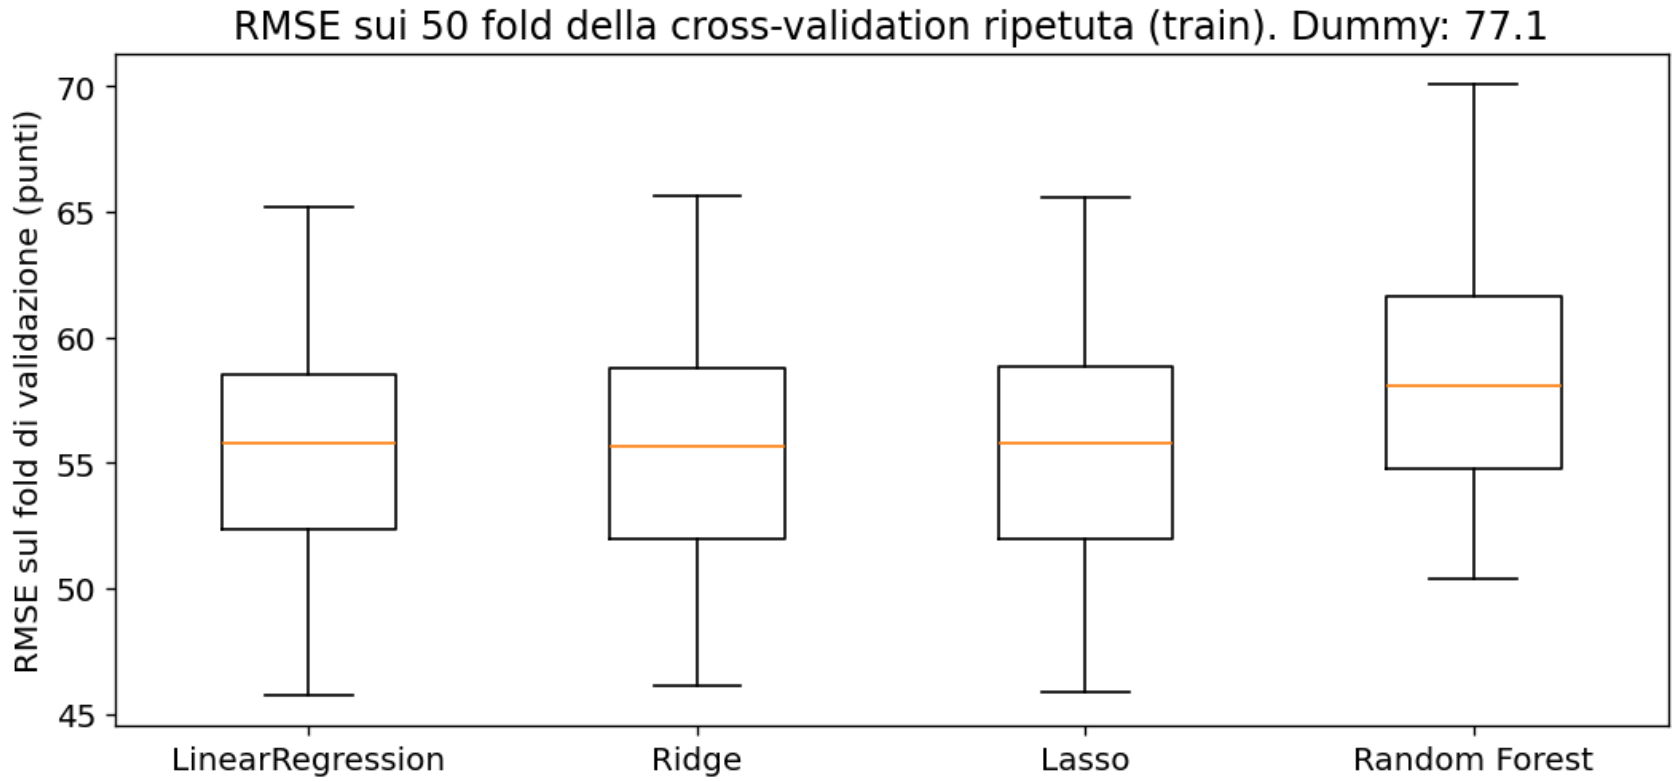
Fonte: dataset Diabetes di scikit-learn

Fino a 10 l'errore cambia pochissimo, oltre 100 sale (underfitting): scelgo 10, il più basso

Apri il notebook

Quale modello in cross-validation?

Stessi 50 fold sul train (10 ripetizioni da 5): regressione lineare, Ridge, Lasso e Random Forest

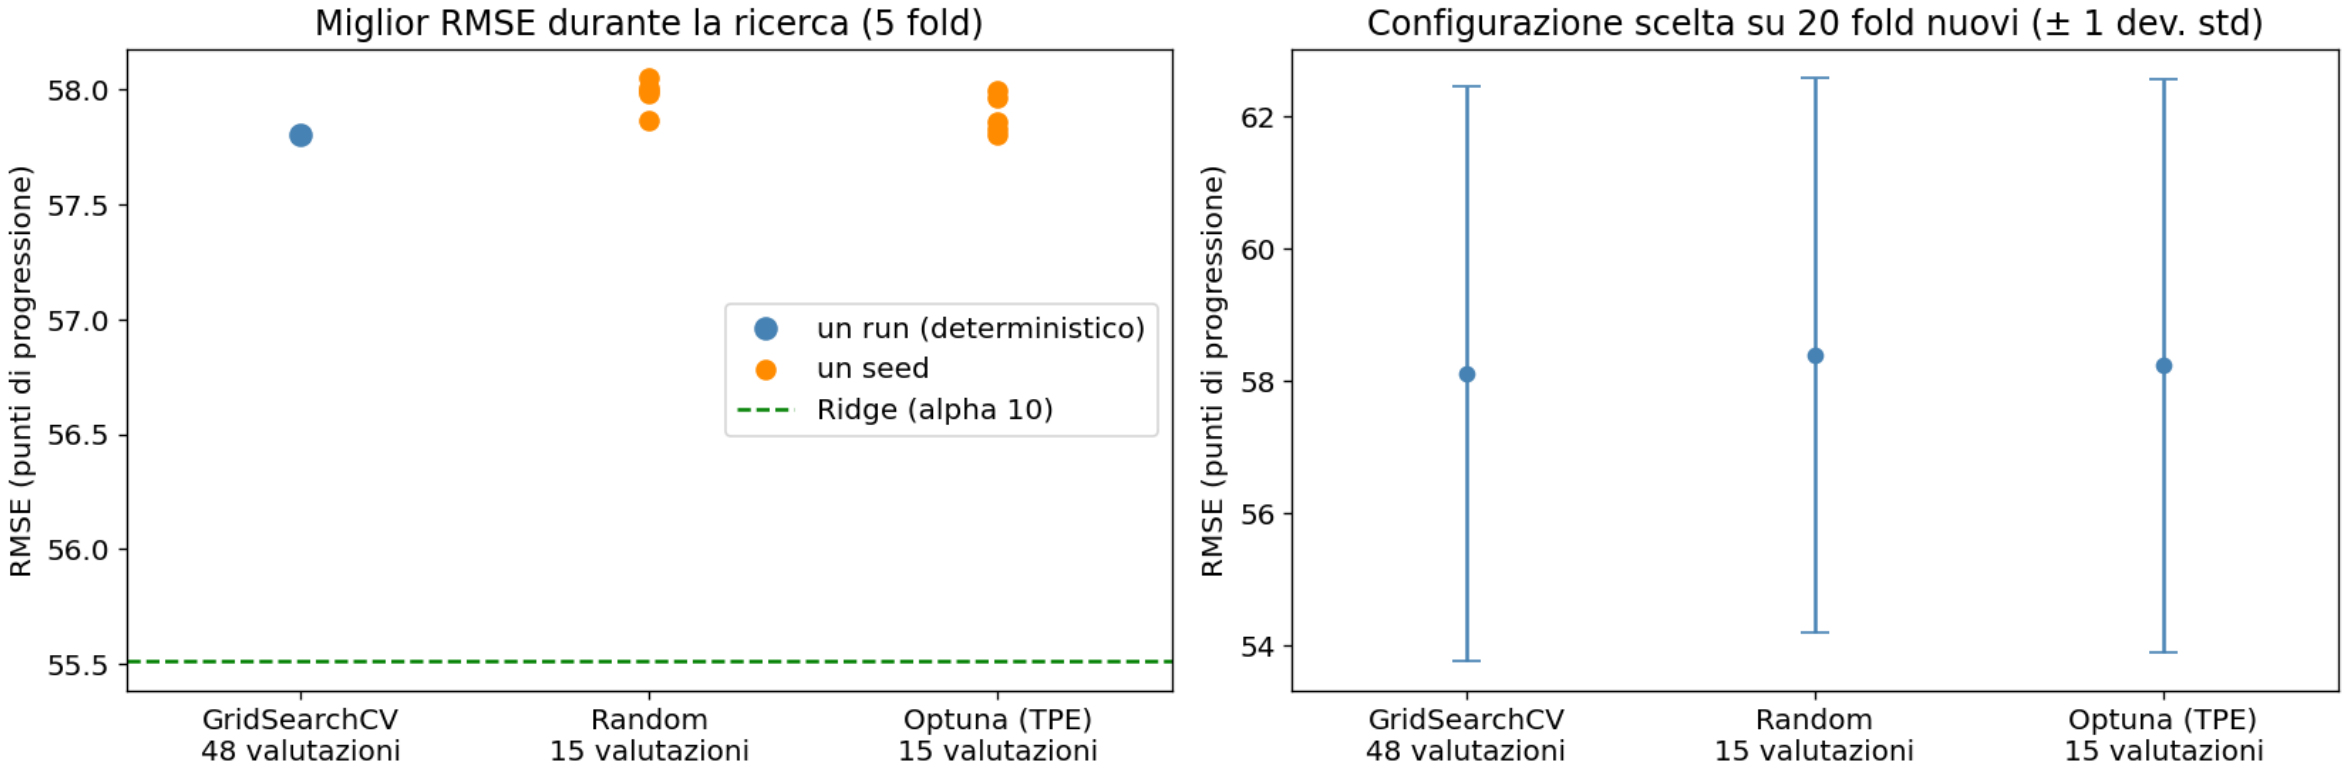


Fonte: dataset Diabetes di scikit-learn

Ridge 55,6 e Random Forest 58,2: la foresta va peggio in 42 fold su 50, ma i fold non sono indipendenti, con la correzione di Nadeau e Bengio p 0,035

Grid, random o Bayesiana?

Random Forest, stessi 5 fold e stessa metrica, a destra le configurazioni scelte rivalutate su 20 fold nuovi

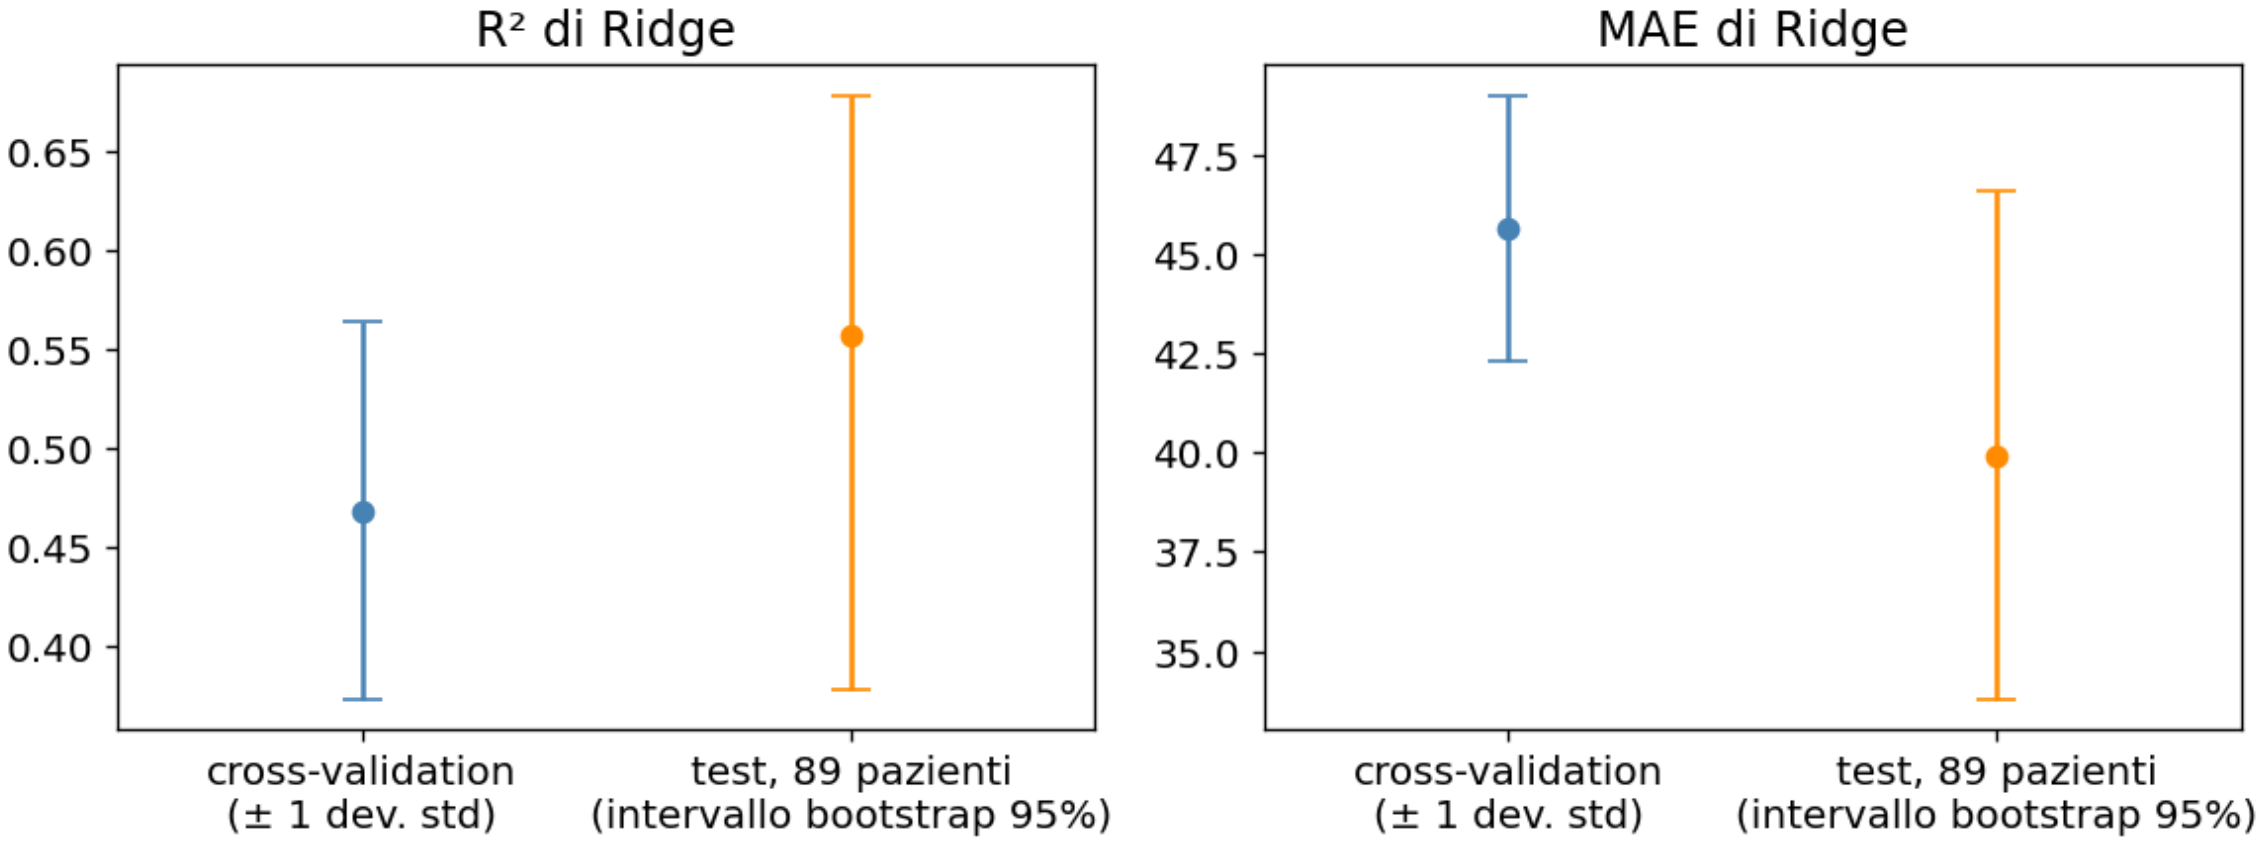


Fonte: dataset Diabetes di scikit-learn

Qualità equivalente, sui fold nuovi 58,1 griglia, 58,2 Optuna e 58,4 casuale con dev. std 4,3, il tempo segue le valutazioni (203 s per 48, 53 s per 15), nessuno avvicina Ridge

Come va sul test?

Ridge riaddestrato su tutto il train, test di 89 pazienti: R^2 0,56 (0,38-0,68), MAE 39,9 (34-47)

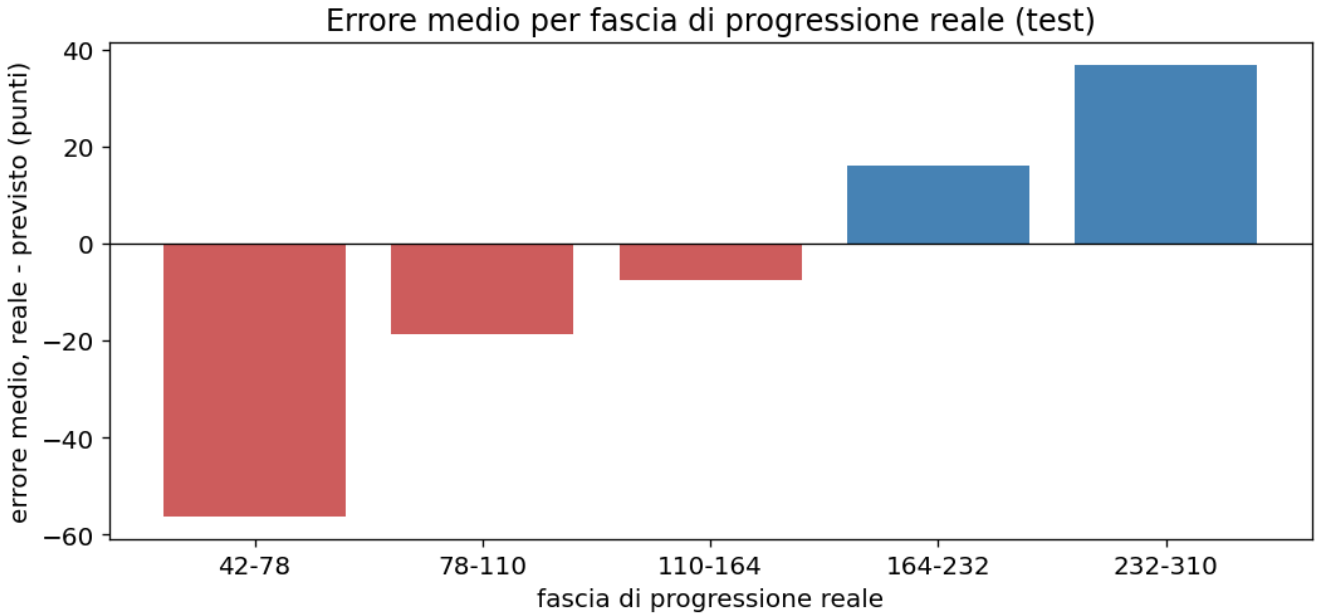


Fonte: dataset Diabetes di scikit-learn

Apri il notebook

Dove sbaglia di più?

Errore medio sul test per fascia di progressione reale (residuo = reale meno previsto)



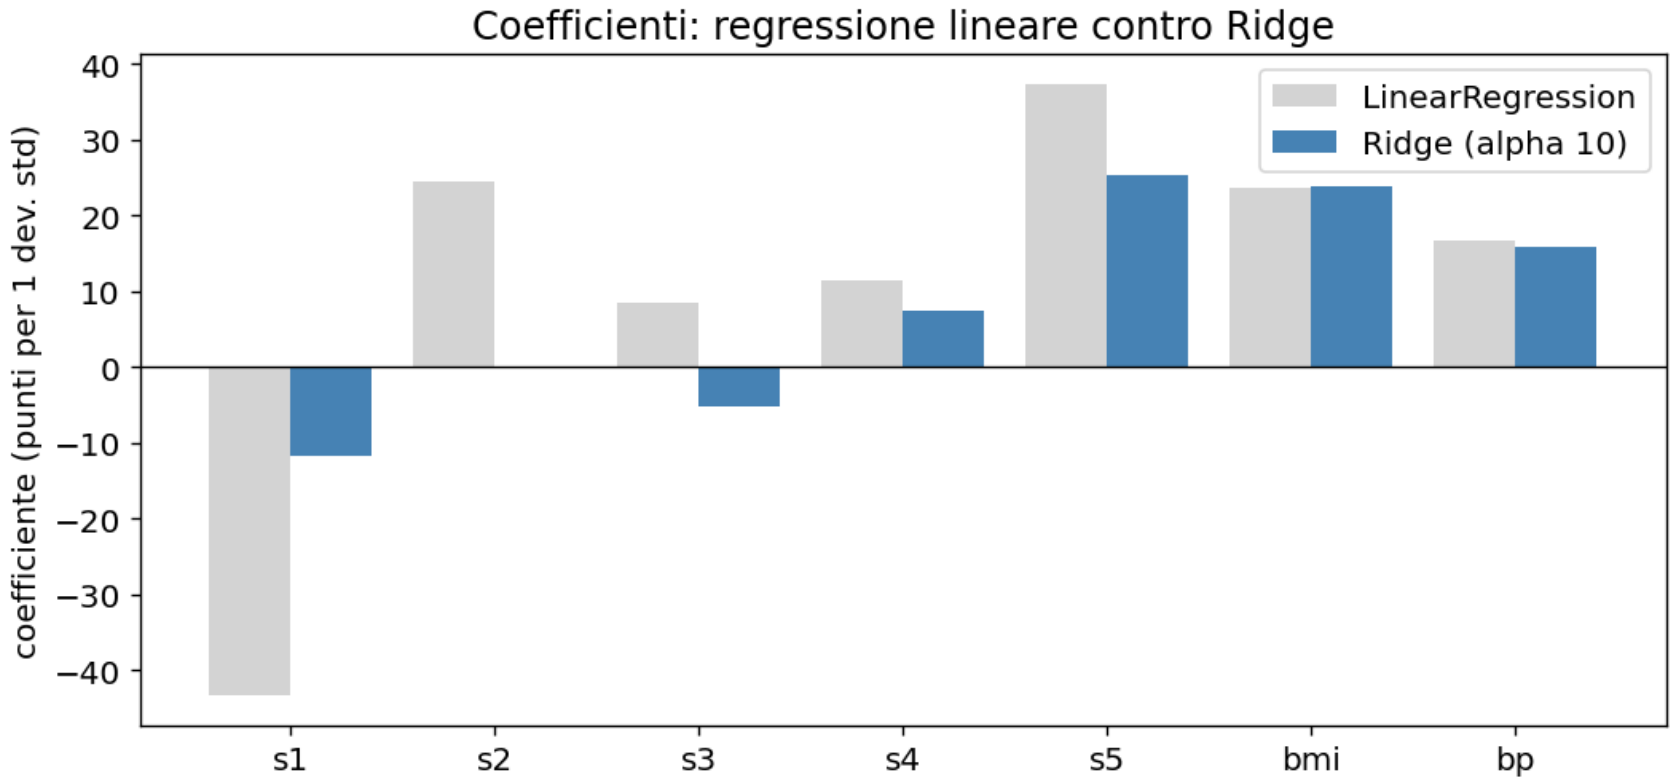
Fonte: dataset Diabetes di scikit-learn

Le previsioni sono schiacciate verso la media: i pazienti che peggiorano di più sembrano meno gravi di quanto sono

Apri il notebook

Regressione lineare o Ridge?

Stesso errore sul test, cambiano i pesi delle variabili gemelle



Fonte: dataset Diabetes di scikit-learn

Con Ridge i pesi si possono spiegare a un medico: contano di più s5 (+25), bmi (+24) e bp (+16)

Conclusioni

Utile per ordinare i pazienti per rischio, non per prevedere il singolo paziente

01

Cosa funziona

R^2 0,56 sul test (0,38-0,68) e 0,47 in cross-validation: il modello impara davvero

02

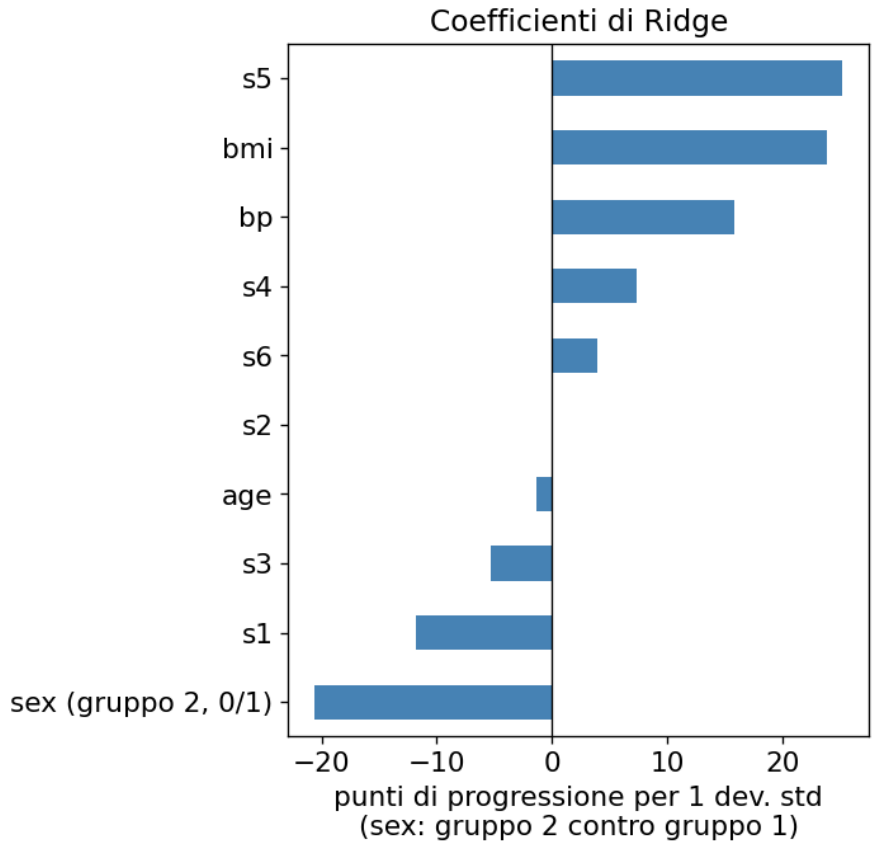
Attenzione

sottostima chi peggiora di più: una previsione media non esclude un peggioramento

03

Prossimi passi

più informazioni cliniche su ogni paziente, come terapie e abitudini



Fonte: dataset Diabetes di scikit-learn