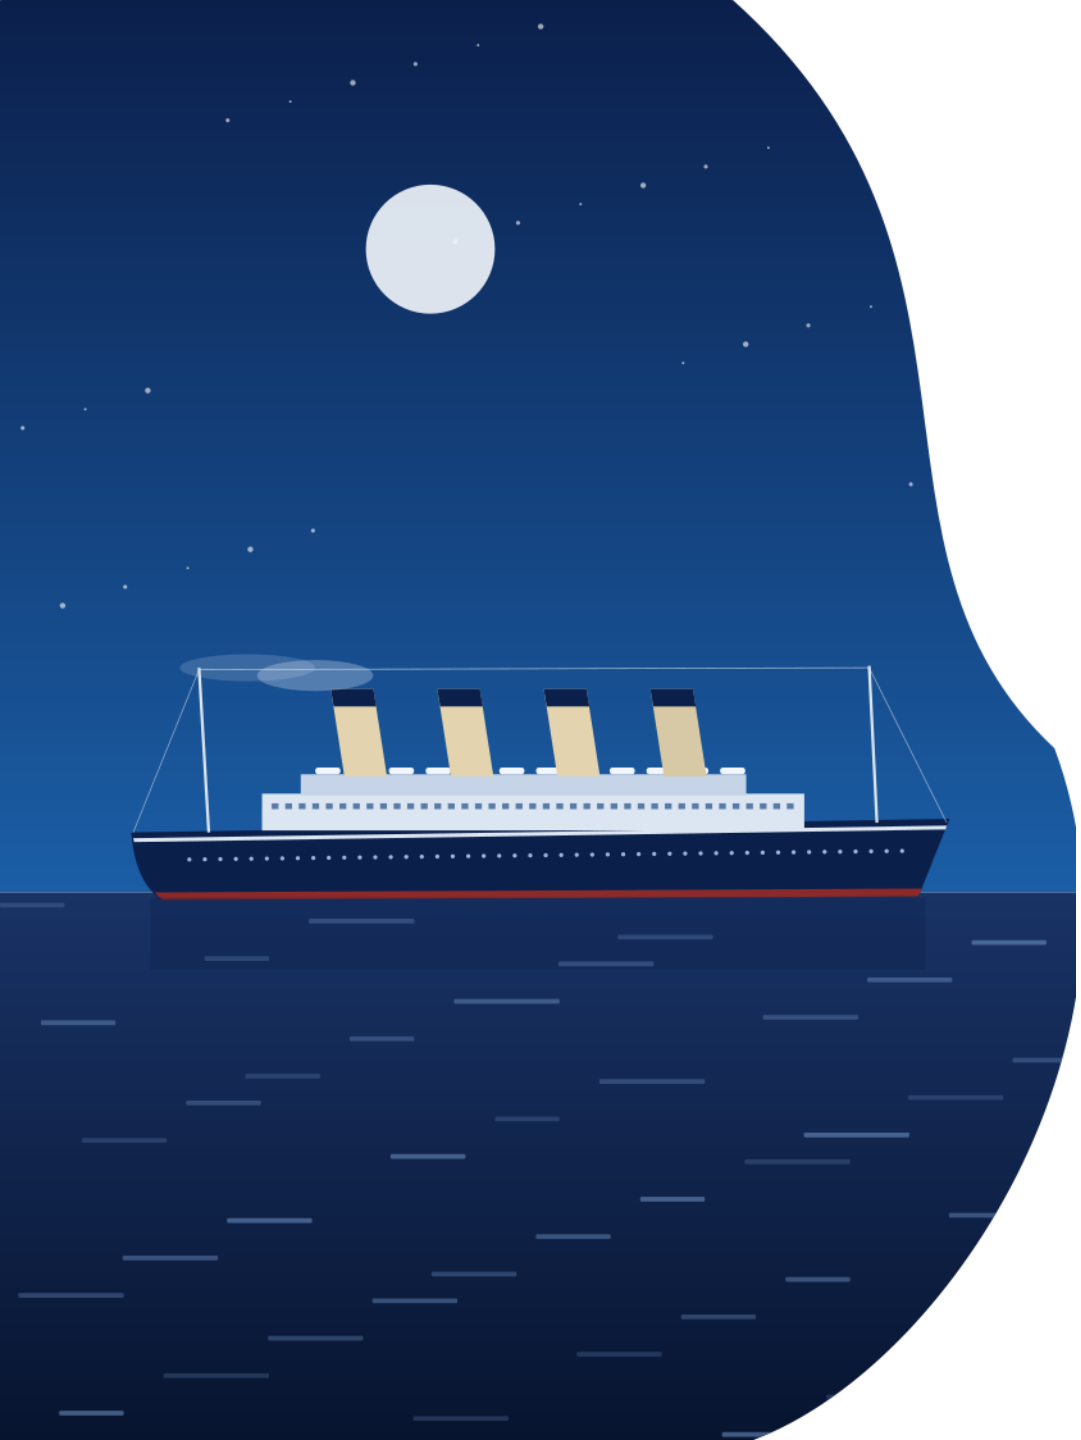


CHI SOPRAVVIVE AL TITANIC?

Un albero di decisione: quanto deve essere profondo e cosa fare con i dati mancanti

Progetto Machine Learning di Daniele Acunzo

Il dataset

Cosa c'è dentro e cosa manca

891

passeggeri (righe)

Indice: PassengerId

l'ho scelto perché è diverso per ogni passeggero

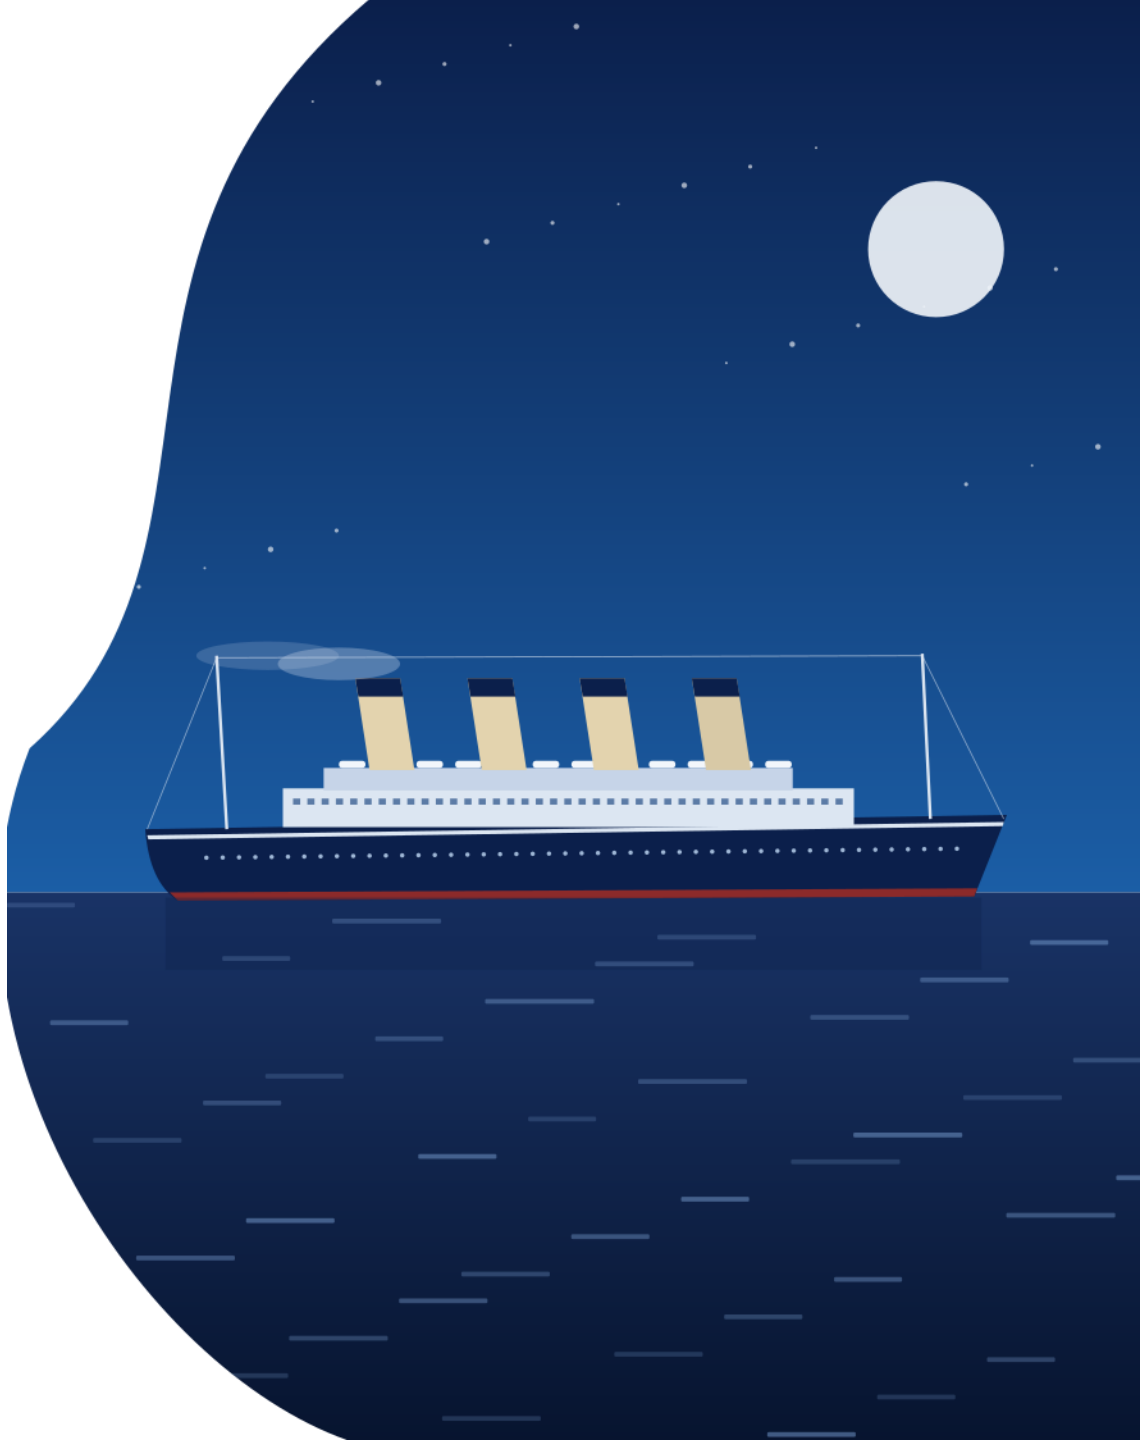
Variabili

Sex · Age · Pclass · Embarked

da prevedere: Survived

Dati mancanti

Age: 177 (media) · Embarked: 2 (porto più frequente)



Cosa dicono i dati

Analisi esplorativa su tutti i 891 passeggeri, prima di costruire il modello

Target

38%

sopravvissuti
sempre "no" = 61,6%

Age

29,7

media (mediana 28)
skew 0,39

Sex

74%

donne
uomini 19%

Pclass

63%

1ª classe
2ª 47% · 3ª 24%

Embarked

55%

porto C
Q 39% · S 34%

Ogni numero motiva una scelta: media per Age, Pclass numerica perché scende in modo costante, OneHotEncoder per Sex ed Embarked, 61,6% come soglia da battere

Apri il notebook

Come ho preparato i dati

Tutto dentro una Pipeline di sklearn, fittata solo sul train

Pipeline	**ColumnTransformer: medie e categorie le impara solo dal train**
Target	**ho separato Survived (y) dalle altre colonne (X)**
Sex, Embarked	**OneHotEncoder: una colonna 0/1 per valore, senza inventare un ordine**
Embarked vuoto	**SimpleImputer: i 2 nulli diventano il porto più frequente, non tolgo righe**
Pclass	**la sopravvivenza scende dalla 1ª alla 3ª classe: c'è un ordine, la lascio numerica**
Age mancante	**SimpleImputer: media del train (29,6 anni), mai calcolata su validation e test**

Come ho diviso i dati

75/25 e poi di nuovo 75/25, seed 0. Con stratify ogni pezzo ha il 38% di sopravvissuti

891

passeggeri

seed 0 + stratify

Train + validation

668

75% · per il modello finale

Train

501

qui l'albero impara

Validation 167 · per scegliere la profondità

Test 223 · 25%

Io uso solo alla fine, una volta sola

Quanto profondo deve essere l'albero?

Ho provato le 5 profondità della consegna e guardato l'accuracy sul validation

max_depth 2

76,6%

accuracy validation

max_depth 5

79,0%

accuracy validation

la scelgo

max_depth 10

78,4%

accuracy validation

max_depth 25

79,0%

accuracy validation

max_depth max

79,0%

accuracy validation

5, 25 e max arrivano tutti a 79,0%: tengo max_depth 5, il più semplice

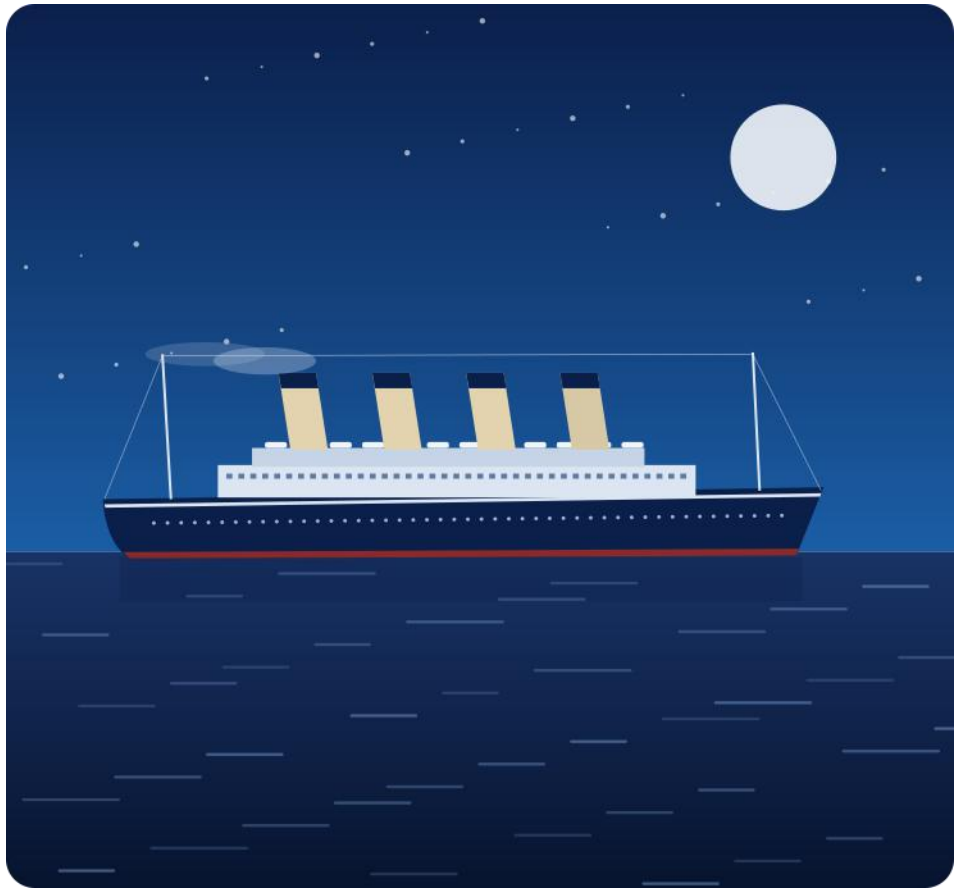
Apri il notebook

Come va sul test?

max_depth = 5 riaddestrato su train + validation (668 righe), provato una sola volta sul test

77,1%

accuracy sul test



Apri il notebook

L'albero batte una baseline?

Logistic Regression con la stessa pipeline, stessi split, stesso refit su train + validation

Albero (max_depth 5)	Baseline
Decision Tree il modello della consegna	**Logistic Regression** un modello più semplice
Validation accuracy: 79,0%	**Validation** accuracy: 77,8%
77,1% accuracy test	**78,5%** accuracy test

Sul validation vince l'albero, sul test la baseline: 3 passeggeri su 223. Con 4 variabili l'albero aggiunge poco.

Non solo accuracy

Confusion matrix dell'albero sul test (223 passeggeri): i non sopravvissuti li riconosce quasi tutti (93%)

	Previsto: non sopravvissuto	Previsto: sopravvissuto
	128 non sopravvissuti riconosciuti	**9** dati per sopravvissuti, ma non lo erano
	42 sopravvissuti che l'albero non vede	**44** sopravvissuti riconosciuti

Accuracy 77%, ma l'albero riconosce solo il 51% dei sopravvissuti (44 su 86). La baseline arriva al 67%.

Parte opzionale: altri modi per l'età mancante

Al posto della media ho provato altre 3 strade, sempre sulle 891 righe

Mediana

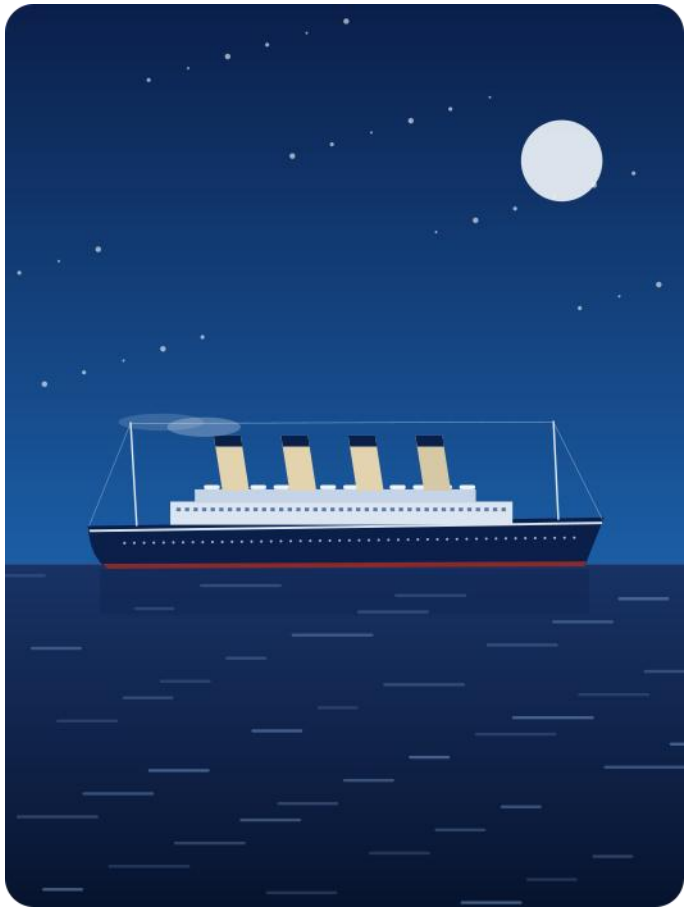
ho messo la mediana del train: 29 anni

NaN all'albero

non riempio niente: l'albero di sklearn (dalla 1.3) accetta i NaN

Senza valori nulli

ho tolto chi non aveva l'età: restano 714 passeggeri



Il resto è identico: stessa pipeline, stessi split stratificati, refit su train + validation

Apri il notebook

Opzionale: come gestire i valori nulli?

Accuracy per ogni modo di trattare Age. Media e mediana sono calcolate su train + validation (668 righe), mai sul test

Media	Mediana	NaN all'albero	Senza valori nulli
891 righe media train + val: 29,8	**891 righe** mediana train + val: 29	**891 righe** Age non riempita	**714 righe** tolte le righe senza età
max_depth 5 accuracy validation: 79,0%	**max_depth 5** accuracy validation: 79,0%	**max_depth 5** accuracy validation: 80,2%	**max_depth 2** accuracy validation: 79,9%
77,1% accuracy test (223 righe)	**77,1%** accuracy test (223 righe)	**75,3%** accuracy test (223 righe)	**77,1%** accuracy test (179 righe)

Media e mediana danno lo stesso albero. I NaN all'albero vincono sul validation (80,2%) ma perdono sul test (75,3%)

Sviluppi futuri

Cosa migliorerei nelle prossime versioni del modello

01

Più variabili
aggiungere tariffa, famiglia e cabina: ora ce ne sono solo 4

02

Cross-validation
al posto di un solo split, per avere risultati più stabili

03

Altri modelli
una random forest, confrontata con albero e baseline anche sulla recall

